

UNIVERSIDAD [NOMBRE]

TENGO QUE PONER LA PORTADA OFICIAL

Trabajo de Fin de Máster

**Análisis y Simulación del Sistema
Electoral Español**

Autor:

[Tu Nombre]

[Fecha]

Resumen

Este trabajo propone un modelo predictivo para las elecciones generales en España fundamentado en indicadores socioeconómicos objetivos, evitando el sesgo inherente a las encuestas tradicionales. Se integran datos heterogéneos de renta, mercado laboral y demografía de los más de 8.000 municipios españoles para caracterizar el entorno material del votante. La metodología emplea técnicas de *Gradient Boosting* tras una fase de ingeniería de variables que integra el Índice de Gini y relaciones de vecindad mediante Teoría de Grafos para capturar la influencia espacial y el sentimiento comarcal. El modelo, entrenado con datos de 2019 y validado con los resultados de 2023, reconstruye el arco parlamentario de 350 escaños aplicando la Ley D'Hondt a nivel provincial. Los resultados demuestran una elevada capacidad de inferencia, capturando patrones no lineales entre precariedad social y comportamiento electoral. Se concluye que las condiciones materiales de vida constituyen un rastro estadístico robusto para predecir la composición del Congreso, permitiendo una modelización política basada exclusivamente en datos objetivos.

Abstract

This work proposes a predictive model for general elections in Spain based on objective socioeconomic indicators, thereby avoiding the inherent bias of traditional polling. Heterogeneous data on income, labor market, and demographics from over 8,000 Spanish municipalities are integrated to characterize the material environment of the voter. The methodology employs *Gradient Boosting* techniques following a feature engineering phase that incorporates the Gini Index and neighborhood relationships through Graph Theory to capture spatial influence and regional sentiment. The model, trained on 2019 data and validated against 2023 results, reconstructs the 350-seat parliamentary arc by applying the D'Hondt rule at the provincial level. The results demonstrate a high inference capacity, capturing non-linear patterns between social precariousness and electoral behavior. It is concluded that material living conditions constitute a robust statistical trace for predicting the composition of the Congress, enabling political

modeling based exclusively on objective data.

**REVISAR TRAS COMPLETAR EL TRABAJO YA QUE
PUEDO TENER OTROS RESULTADOS**

Índice general

Resumen	I
1. Introducción y Objetivos	1
1.1. Introducción	1
1.2. Objetivos	2
1.2.1. Objetivo General	2
1.2.2. Objetivos Específicos	2
2. Marco Teórico y Estado del Arte	3
2.1. Clivajes, Élités y la Teoría del Voto Económico	3
2.1.1. La metamorfosis de los clivajes: Del modelo de clases al paradigma de Piketty	3
2.1.2. El voto económico a la primacía de los <i>fundamentals</i> estructurales . . .	3
2.2. El Factor Territorial: La Geografía del Descontento y la “España Vacía” . . .	4
2.2.1. El municipio como unidad de análisis: Heterogeneidad, INE y el archi- vo SEA	4
2.2.2. La “venganza” de los territorios olvidados y el sesgo de la despoblación	4
2.3. Fronteras Metodológicas: Modelización Bayesiana vs. Gradient Boosting . . .	5
2.3.1. Inferencia Bayesiana y datos composicionales en sistemas multipartidistas	5
2.3.2. Machine Learning y la captura de no-linealidad en el bienestar social .	5
2.4. Arquitectura Institucional y Simulación de Escanos	6

2.4.1.	La Ley D'Hondt y la Geografía de la Representación: El Doble Filtro Electoral	6
2.4.2.	El reparto inicial y la desigualdad del voto	6
2.4.3.	La Barrera Electoral Legal del 3 %	6
2.4.4.	El Algoritmo D'Hondt y el "Umbral Natural"	7
2.4.5.	La "España Vacía" y el Sesgo de Concentración	7
3.	Diseño del Proyecto	9
3.1.	Origen y Adquisición de la Información	9
3.2.	Arquitectura del Proyecto y Ciclo de Vida del Dato	10
3.2.1.	Estructura de Almacenamiento y Repositorio	10
3.2.2.	Procedimientos Técnicos y Pipeline	10
3.3.	Análisis Exploratorio de Datos	11
3.3.1.	Distribución Demográfica y Desequilibrio Territorial	11
3.3.2.	Mercado laboral	15
3.3.3.	Renta e igualdad	17
3.3.4.	Análisis de la Variable Objetivo: Comportamiento Electoral	24
4.	Análisis de los Resultados	30
4.1.	Relación con las Materias del Máster	30
4.2.	Resultados Obtenidos	30
5.	Puesta en Marcha	31

6. Consideraciones Éticas y Sociales	32
7. Conclusiones, Estudio Económico y Futuro	33
7.1. Conclusiones	33
7.2. Estudio Económico	33
7.3. Líneas de Futuro	33
Bibliografía	34
A. Anexos	37

1. Introducción y Objetivos

1.1. Introducción

La predicción de los resultados electorales ha sido históricamente uno de los desafíos más complejos dentro de las ciencias sociales y la estadística aplicada. En el contexto español, el sistema de representación proporcional mediante la Ley D'Hondt y la división en 52 circunscripciones provinciales añade una capa de complejidad técnica que requiere una precisión extrema en la estimación del voto a nivel local. Tradicionalmente, este análisis se ha basado en encuestas de intención de voto y sondeos a pie de urna (*exit polls*). Sin embargo, estas metodologías enfrentan una crisis de fiabilidad creciente debido a fenómenos como el sesgo de respuesta, el aumento de los votantes indecisos y el denominado "voto oculto".

Este trabajo parte de la premisa de que el comportamiento electoral no es un fenómeno aislado de carácter puramente emocional, sino que responde de manera endógena a las condiciones materiales y socioeconómicas de los ciudadanos. La hipótesis central sostiene que los indicadores macroeconómicos y demográficos —tales como la renta per cápita, los niveles de desempleo, la desigualdad medida a través del Índice de Gini y la densidad de población— constituyen un rastro estadístico objetivo y medible. Al contrario que las encuestas, estos datos no dependen de la voluntad de comunicación del sujeto, sino de hechos económicos registrados oficialmente.

Mediante el uso de técnicas avanzadas de *Data Engineering* y algoritmos de *Machine Learning*, este proyecto propone un cambio de paradigma: la transición de una predicción basada en la opinión a una inferencia basada en la realidad socioeconómica. Se busca identificar patrones no lineales que vinculen la precariedad o la bonanza económica con tendencias ideológicas específicas, permitiendo modelizar la composición del Congreso de los Diputados sin recurrir a la consulta directa.

1.2. Objetivos

1.2.1. Objetivo General

Desarrollar y validar un sistema de inferencia predictiva que, mediante el análisis de indicadores socioeconómicos municipales y el uso de algoritmos de aprendizaje supervisado, sea capaz de estimar el reparto de los 350 escaños del Congreso de los Diputados en las elecciones generales españolas.

1.2.2. Objetivos Específicos

1. **Ingesta y Fusión de Datos Heterogéneos:** Diseñar un pipeline de datos para la extracción y limpieza de fuentes oficiales (INE, SEPE, IGN) y su integración en un dataset único a nivel municipal que abarque el periodo 2016-2023.
2. **Análisis Exploratorio y Correlacional:** Identificar las variables socioeconómicas con mayor poder predictivo y analizar su impacto en el sesgo de voto mediante técnicas de análisis multivariante.
3. **Modelado de Inferencia Predictiva:** Implementar y optimizar modelos de *Gradient Boosting* que capturen las relaciones complejas entre el entorno económico y la intención de voto, integrando componentes de influencia espacial.
4. **Desarrollo del Motor de Simulación Electoral:** Programar un módulo lógico que traduzca las predicciones de voto municipal en escaños reales, aplicando con rigor la normativa electoral vigente (barreras del 3 % y Ley D'Hondt).
5. **Validación y Backtesting:** Evaluar la precisión del modelo utilizando los resultados de las elecciones de 2023 como conjunto de prueba frente al entrenamiento basado en datos históricos anteriores.

2. Marco Teórico y Estado del Arte

2.1. Clivajes, Élite y la Teoría del Voto Económico

2.1.1. La metamorfosis de los clivajes: Del modelo de clases al paradigma de Piketty

El estudio del comportamiento electoral ha transitado desde los modelos deterministas de la sociología clásica, que vinculaban el voto casi exclusivamente a identidades estables de clase y religión, como lo planteaba Lipset [13], hacia un marco donde la precisión predictiva depende de la integración de variables estructurales dinámicas, tal como exponen Alaminos-Fernández y Alaminos [8]. En este cambio de paradigma, la obra de Piketty [15, 16] resulta esencial al proponer que las democracias occidentales han evolucionado hacia un sistema de “élites múltiples”.

Bajo esta premisa, el conflicto político actual se articula en torno a dos ejes: la “izquierda brahmán” (clase intelectual con alta educación) y la “derecha comerciante” (élite con alta riqueza). Esta fragmentación se ve acentuada por la percepción de abandono de las clases trabajadoras, quienes, al sentirse traicionadas por la izquierda tradicional, oscilan entre la abstención y el apoyo a nuevos partidos populistas, como argumenta Piketty [16]. En España, este fenómeno se traduce en una diversificación del voto donde la narrativa de “crisis y victimización” es capitalizada por formaciones emergentes para movilizar el resentimiento ciudadano (Alcaide Lara [19]).

2.1.2. El voto económico a la primacía de los *fundamentals* estructurales

Si Piketty define a los sujetos, la teoría del voto económico explica el mecanismo de rendición de cuentas. Tradicionalmente, se postula que el elector premia o castiga al gobierno según la prosperidad material, un enfoque descrito por Lewis-Beck y Stegmaier [12]. No obstante, la investigación internacional sugiere que los indicadores económicos directos pueden ser predic-

tores débiles si no se corrigen los sesgos de las encuestas, como indican Kennedy et al. [11].

Por ello, este TFM prioriza el uso de los *fundamentals* o variables estructurales objetivas (renta, desempleo, educación) sobre la demoscopia tradicional. La viabilidad de este enfoque ha sido validada en el contexto español por Albaladejo [9], quien demuestra que es posible predecir el bloque ganador a nivel municipal con altísima precisión sin recurrir a sondeos, basándose únicamente en la “huella dactilar” socioeconómica del territorio.

2.2. El Factor Territorial: La Geografía del Descontento y la “España Vaciada”

2.2.1. El municipio como unidad de análisis: Heterogeneidad, INE y el archivo SEA

La mayoría de los modelos convencionales operan a nivel provincial, escala que diluye las profundas asimetrías internas del territorio. Esta investigación utiliza el municipio como unidad mínima ($n > 8,000$) para capturar dinámicas micropolíticas invisibles en análisis agregados. Este nivel de detalle es posible gracias al INE que publica los datos municipales, además estudios como *Spanish Electoral Archive* (SEA), que ha homogeneizado los resultados históricos en España hasta el nivel de mesa electoral (Pavía y Cantarino [14]), permitiendo una granularidad estadística sin precedentes, en caso de querer estudiar la muestra usando más años como referencia.

2.2.2. La “venganza” de los territorios olvidados y el sesgo de la despo- blación

El auge de nuevos comportamientos electorales responde a lo que Rodríguez-Pose [17] denomina “la venganza de los lugares que no importan”: una reacción de los territorios en declive demográfico contra las élites urbanas. En España, este fenómeno se manifiesta en la “España vaciada”, donde la migración de los jóvenes hacia las urbes deja un censo envejecido y masculinizado que tiende a concentrar el voto en opciones conservadoras, fenómeno analizado por

Sánchez-García y Rodon [18]. Integrar estas variables de vulnerabilidad y trayectoria histórica permite al modelo ir más allá de las métricas económicas clásicas, tal como sugiere Lastras Rodríguez [22]. Por lo tanto es importante tener en cuenta la edad media de los municipios especialmente de los rurales.

2.3. Fronteras Metodológicas: Modelización Bayesiana vs. Gradient Boosting

2.3.1. Inferencia Bayesiana y datos composicionales en sistemas multipartidistas

Predecir resultados en sistemas multipartidistas requiere modelos capaces de gestionar la incertidumbre y la naturaleza composicional del voto (donde la suma de las partes siempre es 100 %). Los enfoques Bayesianos Dinámicos (Stoetzer et al. [25]) y los modelos jerárquicos bayesianos (Deb et al. [10]) son fundamentales aquí, ya que permiten estabilizar estimaciones en municipios pequeños mediante el uso de *priors* estructurales y secuencias multinomiales, incluso ante información parcial. Esta metodología es ideal para tratar el voto como un todo coherente, como exponen Aguilar López y Aquino López [20].

2.3.2. Machine Learning y la captura de no-linealidad en el bienestar social

Como contraparte, algoritmos de Machine Learning como XGBoost o Random Forest destacan por su capacidad para detectar interacciones no lineales entre variables socioeconómicas, tal y como señalan Alaminos-Fernández y Alaminos [8]. Experiencias internacionales recientes han demostrado que combinar estos algoritmos con transformaciones matemáticas de datos composicionales permite mapear con éxito el espectro ideológico izquierda-derecha a nivel local (Leal Varón et al. [23]). Mientras el enfoque Bayesiano garantiza robustez teórica y gestión de la incertidumbre, el Gradient Boosting ofrece una precisión superior en la captura de patrones complejos de bienestar y comportamiento electoral urbano (Lastras Rodríguez [22]).

2.4. Arquitectura Institucional y Simulación de Escaños

2.4.1. La Ley D'Hondt y la Geografía de la Representación: El Doble Filtro Electoral

El sistema electoral para el Congreso de los Diputados, regulado por la LOREG, opera bajo un modelo de proporcionalidad corregida que transforma la realidad socioeconómica municipal en poder legislativo a través de 52 distritos independientes. Para que la simulación de escaños de este TFM sea robusta, el modelo debe gestionar la interacción entre la barrera legal mínima y la magnitud de las circunscripciones.

2.4.2. El reparto inicial y la desigualdad del voto

De los 350 escaños totales, la asignación no es puramente poblacional. El sistema otorga un mínimo inicial de dos escaños a cada provincia, mientras que las ciudades autónomas de Ceuta y Melilla disponen de un único escaño cada una (que opera de facto como un sistema mayoritario uninominal). Los 248 escaños restantes se distribuyen proporcionalmente según la población.

Esta regla genera una sobrerrepresentación de las provincias pequeñas: mientras que en Madrid o Barcelona se necesitan aproximadamente 130.000 votos para obtener un diputado, en provincias como Teruel o Soria la cifra desciende por debajo de los 40.000. Para un modelo de Machine Learning, esto implica que el error de predicción en municipios de provincias pequeñas tiene un impacto proporcionalmente mayor en la composición final del Congreso que en las grandes urbes.

2.4.3. La Barrera Electoral Legal del 3 %

El artículo 163 de la LOREG estipula que solo se consideran para el reparto aquellas candidaturas que alcancen, al menos, el 3 % de los votos válidos en la circunscripción provincial, cualquier partido que tras la agregación municipal no alcance este 3 % provincial es excluido

automáticamente del proceso, y sus votos se consideran “perdidos” a efectos de representación. En este punto, el voto en blanco adquiere una relevancia crítica para las fuerzas minoritarias: al ser considerado voto válido, se incluye en el denominador del cálculo del porcentaje.

Efecto Matemático: Un incremento en el voto en blanco eleva el número absoluto de votos necesarios para superar el umbral del 3 %. Si V_c son los votos a candidaturas y V_b los votos en blanco, la barrera legal B_l se define como:

$$B_l = 0,03 \times (V_c + V_b) \quad (2.1)$$

Por tanto, una elevada participación de voto en blanco perjudica directamente a los partidos pequeños que orbitan cerca del margen de exclusión, impidiendo su entrada en el reparto de D’Hondt.

2.4.4. El Algoritmo D’Hondt y el “Umbral Natural”

Una vez superado el filtro del 3 %, los escaños se distribuyen mediante la Ley D’Hondt, utilizando la fórmula de divisores sucesivos:

$$\text{Cociente} = \frac{V_i}{s_i + 1} \quad (2.2)$$

En provincias de magnitud baja (que reparten entre 2 y 5 escaños), el umbral natural, el porcentaje real de votos necesarios para obtener el último escaño disponible, suele oscilar entre el 15 % y el 25 % (Montero y Riera [24]). En estos casos, la barrera legal del 3 % es una anécdota estadística, ya que un partido puede triplicar ese porcentaje y aun así quedar fuera del Parlamento.

2.4.5. La “España Vacía” y el Sesgo de Concentración

El impacto de la despoblación es determinante: el sistema penaliza a la tercera y cuarta fuerza política nacional si su voto está disperso, beneficiando a partidos que logran concentrar sus apoyos en zonas rurales o a partidos regionalistas con bases sólidas en provincias específicas (Lago y Martínez [21]). Como indican Sánchez-García y Rodon [18], este diseño tiende a so-

brerrepresentar a las opciones conservadoras que dominan el ámbito rural, donde los escaños son “más baratos” en términos de votos absolutos.

3. Diseño del Proyecto

En este capítulo se describe la estrategia técnica adoptada para la resolución del problema planteado. El diseño se fundamenta en la construcción de un ecosistema de datos robusto y una arquitectura de procesamiento modular que permite transformar información administrativa bruta en conocimiento predictivo.

3.1. Origen y Adquisición de la Información

La construcción del dataset maestro ha requerido una fase intensiva de adquisición de datos procedentes de diversos organismos de la Administración Pública. La estrategia de obtención se ha centrado en capturar tres dimensiones críticas del electorado: su comportamiento histórico, su situación económica y su entorno demográfico-espacial.

Los resultados electorales y los datos de escrutinio municipal se han obtenido a través del portal de descargas del Ministerio del Interior [1], recuperando los registros detallados de los procesos de 2016, 2019 y 2023. Para la caracterización socioeconómica, el núcleo de la información proviene del Instituto Nacional de Estadística (INE), específicamente del Atlas de Distribución de Renta de los Hogares [2]. Esta fuente aporta indicadores de renta neta, fuentes de ingresos y métricas de desigualdad que permiten modelizar el contexto material del votante. Debido a las particularidades del sistema foral, esta información se ha complementado con los microdatos de renta proporcionados por Nastat [3] para la Comunidad Foral de Navarra.

Adicionalmente, se ha integrado la visión coyuntural del mercado laboral mediante las estadísticas mensuales de paro y contratos del SEPE [4], así como la estructura demográfica oficial a través del Padrón Municipal del INE [5]. Finalmente, para dotar al modelo de una dimensión espacial, se han incorporado las delimitaciones territoriales del Instituto Geográfico Nacional [6] y, para la vertiente ideológica, las escalas de autopoicionamiento del Centro de Investigaciones Sociológicas [7]. Esta amalgama de fuentes heterogéneas constituye la base empírica sobre la que se asienta el resto de la arquitectura técnica.

3.2. Arquitectura del Proyecto y Ciclo de Vida del Dato

La arquitectura del sistema se ha diseñado bajo un enfoque de ingeniería de datos modular, asegurando que cada etapa del proceso sea reproducible y escalable. El flujo de trabajo se organiza siguiendo una estructura de directorios que refleja el ciclo de vida de la información: de lo "sucio"(*raw*) a lo "procesado".

3.2.1. Estructura de Almacenamiento y Repositorio

El proyecto se organiza en cuatro capas de datos y tres módulos lógicos de ejecución, lo que permite una clara separación de responsabilidades:

- **Capa de Datos Brutos (*data_raw/*):** Almacena la información original sin modificar, manteniendo la fidelidad a la fuente. Se organiza por categorías (renta, votos, mercado laboral, etc.).
- **Capa de Procesamiento Lógico (*limpieza/*):** Contiene los scripts ETL (*Extract, Transform, Load*) encargados de normalizar formatos, gestionar valores nulos y estandarizar las claves de unión (códigos INE municipales).
- **Capa de Datos Limpios (*data_processed/*):** Almacena los DataFrames resultantes tras la limpieza. Es la fuente de verdad para el análisis y el modelado.
- **Capa de Análisis y Modelado (*EDA/* y *calculos_electorales/*):** Donde se ejecutan los análisis estadísticos y el motor de la Ley D'Hondt.

3.2.2. Procedimientos Técnicos y Pipeline

El procedimiento operativo comienza con la ejecución de la función orquestadora `ETL_limpieza` dentro de `main.ipynb`, la cual invoca secuencialmente los módulos de la carpeta `limpieza/`. Una vez consolidado el dataset maestro en memoria, el sistema procede al Análisis Exploratorio de Datos para validar correlaciones. Posteriormente, el motor de inferencia alimenta el módulo de simulación electoral, el cual traduce los votos predichos en escaños reales aplicando la normativa electoral vigente. Toda esta arquitectura se gestiona mediante el archivo

`config_path.json`, que centraliza las rutas y parámetros de configuración para garantizar la portabilidad del proyecto.


3.3. Análisis Exploratorio de Datos

3.3.1. Distribución Demográfica y Desequilibrio Territorial

Tras examinar el estado del arte y el flujo de procesamiento de datos, es imperativo analizar los hallazgos derivados del análisis exploratorio. Este paso es fundamental para comprender la naturaleza de las variables que integrarán los modelos predictivos y para caracterizar el comportamiento electoral en las elecciones al Congreso de los Diputados, desplazando el foco de análisis hacia la unidad municipal ($n > 8,000$).

Estructura y Densidad Municipal


En primer lugar, se analiza la tipología de los municipios y su densidad poblacional. Tomando como referencia el Padrón Continuo de 2019, España contaba con una población de 47.026.208 habitantes.



Como se observa en el histograma de distribución de frecuencias, la mayor concentración de municipios se sitúa en el intervalo comprendido entre 10² y 10³ habitantes. En una escala

lineal, esta variable presenta una fuerte asimetría con un marcado sesgo positivo, consecuencia de la existencia de un reducido número de grandes áreas metropolitanas frente a una vasta cantidad de pequeños núcleos rurales. No obstante, al aplicar una transformación logarítmica, la distribución adopta una morfología gaussiana, lo que confirma que la población municipal en España sigue una distribución log-normal.

Para profundizar en esta estructura, se ha replicado la categorización oficial del INE, que segmenta los municipios en 11 grupos según su volumen demográfico. El análisis permite contrastar el peso relativo de cada categoría sobre el total de ayuntamientos frente a su contribución real a la población nacional.



Los resultados revelan un marcado contraste demográfico: los municipios con menos de 500

habitantes representan el 49,1 % de las entidades locales, pero albergan únicamente al 1,6 % de la población. En el extremo opuesto, las grandes urbes (más de 100.000 habitantes) constituyen apenas el 0,8 % de los ayuntamientos, pero concentran el 40 % del total nacional. Destaca que la mayor acumulación demográfica reside en ciudades de tamaño medio-alto (entre 100.000 y 500.000 habitantes), que agrupan al 23,8 % de la población. Asimismo, la densidad media nacional se sitúa en 93,17 hab/km².


10 MUNICIPIOS MÁS POBLADOS		
1. Madrid		3,266,126 habs.
2. Barcelona		1,636,762 habs.
3. València		794,288 habs.
4. Sevilla		688,592 habs.
5. Zaragoza		674,997 habs.
6. Málaga		574,654 habs.
7. Murcia		453,258 habs.
8. Palma		416,065 habs.
9. Palmas de Gran Canaria, Las		379,925 habs.
10. Bilbao		346,843 habs.
10 MUNICIPIOS MENOS POBLADOS		
1. Illán de Vacas		3 habs.
2. Villarroya		5 habs.
3. Jaramillo Quemado		7 habs.
4. Arandilla del Arroyo		7 habs.
5. Valtablado del Río		7 habs.
6. Estepa de San Juan		7 habs.
7. Castilnuevo		8 habs.
8. Valdemadera		8 habs.
9. Valdeprado		8 habs.
10. Villanueva de Gormaz		8 habs.

Esta polarización se hace evidente al observar los valores extremos: mientras las dos principales metrópolis superan el millón de habitantes, los municipios más pequeños de la muestra no alcanzan los 10 residentes.

Análisis Provincial y Desequilibrio Representativo

Al elevar el nivel de agregación al plano provincial, Madrid y Barcelona se consolidan como los polos demográficos dominantes, acumulando el 26,2 % de la población total. El siguiente diagrama de dispersión analiza este fenómeno mediante tres dimensiones clave:

- **Densidad Poblacional:** Representada por el tamaño de las esferas, permite identificar visualmente la saturación de habitantes por kilómetro cuadrado.
- **Línea de Equilibrio (Bisectriz):** Esta línea discontinua proyecta una distribución teórica de proporcionalidad perfecta, donde el peso demográfico de una provincia es equivalente a su peso territorial.
- **Identificación de Desequilibrios:** Las provincias situadas significativamente por debajo de la bisectriz (como Soria o Teruel) evidencian un desequilibrio territorial crítico: poseen una vasta superficie pero una reducida carga demográfica. Debido al sistema electoral español, que garantiza un mínimo de dos escaños por provincia, estos territorios presentan una sobrerrepresentación electoral en relación con su censo.





Nota aclaratoria: Se ha optado por excluir a las ciudades autónomas de Ceuta y Melilla de la visualización del scatterplot. Debido a su naturaleza estrictamente urbana y su reducida extensión geográfica, sus densidades extremas distorsionaban la escala visual del análisis; no obstante, su peso estadístico ha sido computado de forma independiente, obteniendo Ceuta una densidad de 4.266,58 hab/km² y Melilla 6.072,33 hab/km².

Por el contrario, las provincias situadas por encima de la línea de equilibrio, aquellas con alta densidad habitacional, experimentan una subrepresentación relativa. A pesar de elegir un mayor número de diputados en términos absolutos, el coste en votos "por escaño es superior al de las provincias despobladas, alejándose de un reparto estrictamente proporcional.

3.3.2. Mercado laboral



Una vez caracterizada la distribución demográfica, se procede a evaluar las variables relativas al mercado laboral, las cuales constituyen predictores fundamentales en la modelización del voto.

Distribución Real de Contratos por Sector (Total Nacional)



Los datos analizados corresponden a noviembre de 2019, coincidiendo con el marco temporal de las elecciones generales de dicho año. En lo que respecta a la especialización productiva, el sector servicios actúa como el motor principal de la economía española, representando el 70,2 % de la contratación nacional y consolidándose como la actividad mayoritaria en más de 7.000 municipios.

A gran distancia le sigue el sector agrícola, que agrupa el 14,3 % de los contratos y se mantiene como la principal fuente de empleo en 749 municipios, evidenciando su relevancia en la vertebración del voto rural. Por su parte, el sector industrial representa el 10 % de las firmas contratantes, liderando el mercado laboral en 199 localidades. Finalmente, la construcción, con un volumen de contratación del 5,4 %, es el sector dominante en apenas 179 municipios, mostrando una dispersión territorial similar a la industria pero con menor peso relativo en el cómputo total de contratos.



La tasa media de temporalidad nacional en el periodo de referencia se sitúa en un 90,3 %, una cifra que refleja la precariedad estructural del mercado laboral español en dicha etapa. Este porcentaje, si bien es elevado, responde a dos factores clave del contexto socioeconómico:


- **Coyuntura Estacional:** Noviembre marca el inicio de las campañas de contratación masiva vinculadas al Black Friday y el periodo navideño, concentradas mayoritariamente en el sector servicios.
- **Marco Regulatorio:** El mercado operaba bajo la normativa previa a la reforma laboral de 2021. Por tanto, los datos capturan de forma fidedigna la alta volatilidad contractual previa a las restricciones legales impuestas posteriormente a la contratación eventual.

El análisis de la temporalidad por sectores revela dinámicas heterogéneas. Mientras que la construcción presenta una baja dispersión, indicando un comportamiento homogéneo en todo el territorio, la industria muestra una variabilidad significativa. Es especialmente reseñable el comportamiento del sector servicios, que acumula la mayor cantidad de outliers. Esta dispersión evidencia realidades laborales polarizadas, condicionadas por la especialización turística o la capacidad comercial de cada entidad municipal.

3.3.3. Renta e igualdad

Desigualdad


A partir de este epígrafe, el análisis se ve condicionado por el secreto estadístico. El INE restringe la publicación de datos en municipios de baja densidad (habitualmente menores de 100 habitantes) para garantizar el anonimato de los ciudadanos. Asimismo, la gestión de los datos de la Comunidad Foral de Navarra se ha realizado a través del Instituto de Estadística de Navarra (Nastat). Debido a su régimen foral, los indicadores publicados no siempre presentan una equivalencia directa con el sistema común, lo que ha derivado en una reducción de la muestra final. En total, se han identificado 1.421 municipios con ausencia de datos (NA), lo que representa el 17,5 % del territorio nacional.



Para la interpretación de la desigualdad, se emplea el Índice de Gini, una medida que oscila entre 0 (igualdad total) y 100 (desigualdad máxima). Los resultados muestran que los municipios con mayor polarización presentan índices de Gini de entre 44 y 45,2, donde la población con mayores ingresos percibe hasta 4,6 veces más que el estrato más humilde. En el extremo opuesto, los municipios con mayor cohesión social muestran valores cercanos a 20,3, con una diferencia de ingresos reducida a un ratio de entre 1,8 y 1,9.

Nota Metodológica: Para el cálculo de la diferencia de ingresos, se ha excluido a Navarra del indicador P80/P20 (ratio entre el percentil 80 y el 20), dado que el Nastat emplea el indicador S80/S20 (ratio de quintiles de renta). Aunque conceptualmente similares, su cálculo


matemático difiere, impidiendo una comparación directa; no obstante, el Índice de Gini sí ha sido homogeneizado para todo el Estado.



En el contexto español, un Gini inferior a 25 denota una igualdad muy alta, mientras que el rango 28-32 representa el estándar medio nacional. Valores superiores a 40 indican una fractura social severa. El histograma de distribución confirma una morfología de campana con una fuerte concentración en el intervalo de 25 a 30 puntos, lo que define la normalidad estadística de una desigualdad moderada en la mayoría del territorio.

Correlación y Validación de Métricas

Se ha realizado un análisis de la relación entre el Índice de Gini y el ratio $P80/P20$ para validar la consistencia de los datos de desigualdad.




Se ha obtenido un coeficiente de correlación de Pearson de $r = 0,790$. Este valor indica una correlación positiva fuerte, confirmando que la desigualdad en España se manifiesta predominantemente como una polarización de los extremos. Matemáticamente, este resultado valida que en los municipios donde el Índice de Gini se eleva, la brecha social se ensancha de forma predecible: el incremento de la renta en el bloque superior ocurre de forma simultánea al estancamiento del bloque inferior. Localidades como Villarlengo, con un ratio de 4,6x, tipifican este fenómeno.


Desde la perspectiva de esta investigación, la consistencia estadística observada adquiere una relevancia teórica fundamental. Mientras que los modelos clásicos de ciencia política vinculaban de forma lineal el voto a la clase social, autores como Piketty (2019) argumentan que esta relación se ha transformado: el eje de conflicto ya no se divide estrictamente entre capital y trabajo, sino entre diferentes élites (la élite intelectual o 'izquierda brahmán' y la élite económica o 'derecha comerciante'). Por lo tanto, la inclusión de estas variables de desigualdad en el modelo permitirá contrastar si, en el contexto español, la polarización de rentas mantiene su capacidad predictiva tradicional o si, por el contrario, la reconfiguración de los electorados en torno a nuevos clivajes de élite ha mitigado el impacto de la desigualdad económica local como determinante directo del voto.

Fuentes de ingresos


Tras analizar la desigualdad, es necesario evaluar el comportamiento de los indicadores de renta a nivel municipal. En este punto, persiste la presencia de valores ausentes por secreto estadístico, aunque con una ligera variación en el volumen de nulos respecto a los índices de desigualdad. La representatividad oscila entre un 16,9 % y un 20,8 % de municipios sin datos, debido a que el Instituto de Estadística de Navarra (Nastat) sí proporciona ciertas métricas de renta que no estaban disponibles para los indicadores de polarización.



La práctica totalidad de los valores faltantes se concentra en municipios de menos de 500 habitantes. La única excepción es el municipio de Arraia-Maeztu (726 habitantes); su ausencia de datos se atribuye a las particularidades en la captación y publicación de estadísticas en el marco del concierto económico del País Vasco, que, al igual que el régimen foral navarro, gestiona su propia información tributaria y estadística.



Al contrastar la renta bruta frente a la renta neta, se evidencia el impacto del sistema redistributivo. Estadísticamente, la transición hacia valores netos produce un desplazamiento de la curva de densidad hacia la izquierda y una marcada compresión de la varianza, lo que reduce la dispersión en los deciles de ingresos más altos. Mientras que la renta bruta media por hogar se sitúa en el entorno de los 30.000€, la distribución neta se estrecha alrededor de los 25.000€, minorando las distancias relativas entre municipios.




No obstante, desde una óptica metodológica, el uso de la Renta por Unidad de Consumo

(cuyo pico modal se sitúa en los 16.000€) resulta ser la métrica más robusta. Este indicador permite corregir las economías de escala dentro de los hogares, ofreciendo una visión más fidedigna de los niveles de vida reales y presentando una mayor homogeneidad en gran parte del territorio nacional.

Composición de las Fuentes de Renta y su Dimensión Política


Para concluir el bloque de indicadores condicionados por el secreto estadístico, se analizan las fuentes de ingresos municipales. Esta desagregación es fundamental, ya que la prevalencia de pensiones frente a salarios puede señalar clivajes electorales profundos: desde un voto orientado a la estabilidad del sistema público de previsión social hasta uno más sensible a las dinámicas del mercado laboral y la competitividad económica.



La distribución del **Porcentaje Medio de Ingresos** actúa como un indicador del promedio nacional y revela una jerarquía clara: España es, eminentemente, una economía basada en el trabajo. Los salarios constituyen el 52,6 % de los ingresos medios, seguidos por las pensiones con un 26,9 %. Otras fuentes, como las prestaciones por desempleo o las ayudas sociales, aparecen como componentes residuales que no alcanzan el 5 % del peso total.

Sin embargo, el *boxplot* revela que esta uniformidad es solo aparente. Aunque la mediana del salario es mayoritaria, presenta una **volatilidad intermunicipal** extrema. Es especialmente significativo el comportamiento de las pensiones y otras rentas: a pesar de tener medianas bajas, el gráfico muestra una alta densidad de *outliers* en el decil superior. Esto confirma la existencia de municipios con naturalezas económicas opuestas; verdaderas "islas" demográficas donde la dependencia de la prestación pública o de las rentas patrimoniales anula la relevancia del mercado laboral privado.

Segmentación según Tamaño del Municipio



Al analizar la estructura de ingresos por rango poblacional, se observa una tendencia clara: el crecimiento del municipio correlaciona con una estructura económica más predecible y centrada en el salario.

- **Municipios de baja densidad (<100 a 1.000 hab.):** Es donde reside la mayor volatilidad económica. La cuota salarial es sensiblemente inferior y la dependencia de las pensiones es mucho más elevada. En los núcleos de menos de 100 habitantes, la brecha entre salario y pensiones se estrecha críticamente, reflejando el envejecimiento demográfico de la "paña vaciada".
- **Áreas Metropolitanas (>100.000 a >500.000 hab.):** El escenario se invierte. El salario

se dispara por encima del 60 % y la dispersión se reduce drásticamente. Son entornos de ingresos homogéneos, estrechamente vinculados a la actividad profesional y al sector servicios avanzado.

Posibles Implicaciones para la Modelización Electoral

Esta segmentación por tamaños sugiere dos frentes de batalla electoral muy distintos:

- **El "Voto Seniorz la Seguridad Social:** En municipios pequeños, donde las pensiones representan el eje vital (con medianas que rozan el 40 %), el electorado muestra una sensibilidad extrema a los mensajes sobre la sostenibilidad del sistema público de previsión. La supervivencia económica depende directamente del Estado, lo que suele traducirse en un voto que prima la seguridad y la aversión al riesgo institucional.
- **El "Voto ActivoÜrbano:** En las metrópolis, el motor es el salario. Este electorado es más receptivo a políticas de presión fiscal (IRPF), coste de la vida y dinamismo empresarial. En estas zonas, los programas centrados exclusivamente en las pensiones pueden percibirse como secundarios frente a la gestión de la economía productiva.
- **Transversalidad de las Rentas de Capital:** Resulta notable que la categoría de "otros ingresos"(rentas y capital) mantenga valores atípicos constantes independientemente del tamaño del municipio. Esto sugiere un perfil de votante con alto patrimonio distribuido de forma ubicua, cuya motivación de voto podría estar ligada a la fiscalidad patrimonial, con independencia de su entorno geográfico.

En conclusión, los datos sugieren que una estrategia electoral unidimensional ignora la realidad económica del territorio: los incentivos que movilizan a una urbe de 500.000 habitantes (salario) son diametralmente opuestos a los que rigen en un municipio de 500 residentes (pensiones).


3.3.4. Análisis de la Variable Objetivo: Comportamiento Electoral

Una vez examinados los factores socioeconómicos, se procede a analizar la **variable objetivo** de la investigación: el voto. Este análisis comienza por la **participación electoral**, factor


determinante que modula el impacto de las variables predictoras en el resultado final.

Dinámicas de Participación Electoral

La distribución de la participación electoral en los comicios de noviembre de 2019 sigue una morfología de campana de Gauss, lo que refleja una notable homogeneidad en el comportamiento del electorado español.




El grueso de los municipios se concentra en el intervalo del 70-75 %, alcanzando su frecuencia máxima en torno al 72 %. Aunque se identifican casos atípicos en los extremos (40 % y 100 %), su peso numérico es marginal, confirmando una tendencia central sólida y una baja dispersión generalizada en el territorio.




Al desglosar la participación por rango poblacional, se observa que la mediana permanece constante —cercana al 70 %— en todos los estratos. No obstante, la variabilidad disminuye a medida que aumenta el tamaño poblacional: en las grandes ciudades (>500.000 habitantes), el comportamiento es extremadamente homogéneo y carece de valores atípicos. Por el contrario, en los municipios de menor tamaño, la dispersión es máxima y los *outliers* tienden a ser descendentes. Esto indica que los fenómenos de desmovilización extrema son una particularidad de los núcleos rurales pequeños, con la única excepción del segmento inferior a los 100 habitantes, donde el comportamiento es más errático.

El Fenómeno del Voto en Blanco y sus Implicaciones Legales

Es necesario precisar que una alta participación no se traduce íntegramente en apoyo a formaciones políticas. El **voto en blanco** (voto válido que no respalda ninguna candidatura) juega un rol técnico crucial en el sistema electoral español.





El histograma del voto en blanco presenta un **sesgo positivo extremo**, donde la inmensa mayoría de las localidades registran valores inferiores al 2-3 %. Esto confirma que se trata de una opción minoritaria en el conjunto nacional.

Sin embargo, el análisis mediante *boxplots* revela matices demográficos críticos. En los municipios de menos de 100 habitantes se registran anomalías estadísticas donde el voto en blanco llega a superar el 60 %. Este fenómeno no suele responder a una movilización política coordinada, sino a un **efecto de escala** en censos reducidos o a situaciones de vacío político por la ausencia de candidaturas locales. Esta realidad contrasta con la estabilidad urbana: a partir de los 1.000 habitantes, las desviaciones desaparecen y el porcentaje de voto en blanco se estabiliza, sugiriendo que su uso como herramienta de protesta no es una práctica extendida en las grandes urbes.

Impacto en la Ley D'Hondt

Desde una perspectiva jurídica y estadística, este comportamiento tiene una implicación profunda. Según la normativa electoral española, el voto en blanco computa como voto válido, lo que incrementa el denominador para el cálculo del **umbral del 3 %** necesario para acceder al reparto de escaños en la circunscripción provincial. En consecuencia, una concentración elevada de voto en blanco eleva la barrera electoral real, dificultando la entrada de partidos minoritarios y favoreciendo indirectamente a las formaciones mayoritarias mediante una concentración del voto útil.

Partidos políticos

El sistema de partidos en España presenta una arquitectura compleja donde coexisten formaciones de ámbito estatal con partidos regionalistas y nacionalistas, cuya presencia se circunscribe a demarcaciones provinciales o autonómicas específicas. Asimismo, es frecuente la articulación de coaliciones electorales diseñadas para maximizar la eficiencia del voto bajo el sistema d'Hondt.

En este escenario, los dos partidos mayoritarios (PSOE y PP) concentran, cada uno, más del 20 % del sufragio emitido, contrastando con formaciones marginales como ÜDT", que obtuvo apenas el 0,00011 % (26 votos). Aunque el registro oficial contabilizó 90 partidos políticos en los comicios de 2019, tras consolidar las candidaturas únicas y coaliciones, la cifra se reduce a 62 opciones electorales efectivas.

TOP 5 - CANDIDATURAS MÁS VOTADAS:			
- psoe		6,754,330 votos	28.26%
- pp		5,022,200 votos	21.02%
- vox		3,640,441 votos	15.23%
- podemos-íu		2,364,537 votos	9.89%
- cs		1,637,341 votos	6.85%
TOP 5 - CANDIDATURAS MENOS VOTADAS (con al menos 1 voto):			
- udt		26 votos	0.00011%
- izar		112 votos	0.00047%
- dpl		210 votos	0.00088%
- rísa		229 votos	0.00096%
- centrados		233 votos	0.00098%

Como se observa en la figura superior, la disparidad en la cuota de mercado electoral es extrema. Para que una candidatura sea considerada en el reparto de escaños, debe superar la **barrera legal del 3 % de los votos válidos** en la circunscripción provincial correspondiente.

Bajo este criterio, de las 62 candidaturas iniciales, únicamente 25 logran superar dicho umbral en al menos una provincia. Es importante matizar que superar esta barrera es una condición necesaria, pero no suficiente, para obtener representación parlamentaria, la cual queda supeditada a la asignación final mediante la **Ley d'Hondt**.

En términos generales, el número de candidaturas que superan este filtro por provincia oscila entre 5 y 6. No obstante, se identifica una singularidad en las cuatro provincias de Cataluña,

donde la fragmentación del sistema de partidos y la fortaleza de las formaciones de ámbito regional permitieron que hasta 8 candidaturas superaran simultáneamente el umbral mínimo del 3 %.

4. Análisis de los Resultados

4.1. Relación con las Materias del Máster

[Aquí debes vincular el trabajo con las asignaturas cursadas, como Estadística, Programación, Análisis de Datos, etc.]

4.2. Resultados Obtenidos

[Presentación de las visualizaciones del EDA y resultados de las simulaciones.]

5. Puesta en Marcha

[Guía de uso del proyecto, configuración del archivo `config_path.json` y ejecución del notebook `main.ipynb`.]

6. Consideraciones Éticas y Sociales

[Reflexión sobre el impacto del análisis de datos electorales, la privacidad y la transparencia algorítmica.]

7. Conclusiones, Estudio Económico y Futuro

7.1. Conclusiones

7.2. Estudio Económico

7.3. Líneas de Futuro

Bibliografía

- [1] Ministerio del Interior (2024). *Área de descargas de procesos electorales*. Gobierno de España. Recuperado de <https://infoelectoral.interior.gob.es/es/elecciones-celebradas/area-de-descargas/>
- [2] Instituto Nacional de Estadística (2024). *Atlas de distribución de renta de los hogares*. Serie 2015-2023. Recuperado de <https://www.ine.es/dynt3/inebase/index.htm?padre=12385&capsel=12384>
- [3] Instituto de Estadística de Navarra (2024). *Estadística de renta de las personas físicas y familia*. Recuperado de https://nastat.navarra.es/es/tablas_powerbi/-/tag/estadistica-renta
- [4] Servicio Público de Empleo Estatal (2024). *Datos estadísticos de paro y contratos por municipios*. Recuperado de <https://www.sepe.es/HomeSepe/que-es-el-sepe/estadisticas/datos-estadisticos/municipios.html>
- [5] Instituto Nacional de Estadística (2024). *Padrón municipal de habitantes*. Recuperado de https://www.ine.es/dyngs/INEbase/categoria.htm?c=Estadistica_P&cid=1254734710990
- [6] Instituto Geográfico Nacional (2024). *Delimitaciones Territoriales y Cartografía Municipal (NGMEP)*. Centro de Descargas del CNIG. Recuperado de <https://centrodedescargas.cnig.es/CentroDescargas/detalleArchivo?sec=9000004#>
- [7] Centro de Investigaciones Sociológicas (2022). *Barómetro de diciembre de 2022 (Estudio 3388)*. Recuperado de <https://www.cis.es/>
- [8] Alaminos-Fernández, A. F., & Alaminos, A. (2023). *Métodos y Modelos para la Predicción Electoral. Una Guía Práctica*. Universidad de Alicante.
- [9] Albaladejo Gutiérrez, G. (2025). *Análisis predictivo del comportamiento electoral en España*. Trabajo de Fin de Grado, Universidad Pontificia Comillas.

- [10] Deb, S., Roy, A., & Das, S. (2024). *Forecasting elections from partial information using a Bayesian model*. Journal of Applied Statistics, 51(2), 310-328.
- [11] Kennedy, R., Wojcik, S., & Lazer, D. (2017). *Improving election prediction internationally*. Science, 355(6324), 515-520.
- [12] Lewis-Beck, M. S., & Stegmaier, M. (2019). *Economic Voting*. The SAGE Handbook of Electoral Behaviour.
- [13] Lipset, S. M. (1959). *Some social requisites of democracy: Economic development and political legitimacy*. American Political Science Review, 53(1), 69-105.
- [14] Pavía, J. M., & Cantarino, I. (2021). *Spanish Electoral Archive. SEA database*. Scientific Data, 8(1), 160.
- [15] Piketty, T. (2018). *Brahmin Left vs Merchant Right: Rising Inequality and the Changing Structure of Political Conflict*. WID.world Working Paper.
- [16] Piketty, T. (2021). *Capital e ideología*. Editorial Planeta / Deusto.
- [17] Rodríguez-Pose, A. (2018). *The revenge of the places that don't matter (and what to do about it)*. Cambridge Journal of Regions, Economy and Society, 11(1), 189-209.
- [18] Sánchez-García, J., & Rodon, T. (2023). *Economic perceptions and voting behavior in complex party systems*. Electoral Studies, 82, 102588.
- [19] Alcaide Lara, A. (s.f.). *Evolución del voto y narrativas de crisis*.
- [20] Aguilar López, R., & Aquino López, M. A. (2015). *Modelización de la intención de voto con datos composicionales*. REES: Revista de Estadística, Econometría y Sistemas.
- [21] Lago, I., & Martínez, F. (2013). *La penalización del voto disperso en el sistema electoral español*.
- [22] Lastras Rodríguez, A. (2024). *Captura de patrones complejos de bienestar urbano y comportamiento electoral*.
- [23] Leal Varón, et al. (2025). *Mapeando el espectro ideológico izquierda-derecha con Machine Learning*.

- [24] Montero, J. R., & Riera, P. (2009). *El umbral natural y el sistema electoral en provincias de magnitud baja.*
- [25] Stoetzer, L. F., et al. (2019). *Forecasting elections in multiparty systems: a Bayesian approach.*

A. Anexos

[Tablas adicionales, fragmentos de código o manuales extendidos.]