

UNIVERSIDAD [NOMBRE]

TENGO QUE PONER LA PORTADA OFICIAL

Trabajo de Fin de Máster

**Análisis y Simulación del Sistema
Electoral Español**

Autor:

[Tu Nombre]

[Fecha]

Resumen

Este trabajo propone un modelo predictivo para las elecciones generales en España fundamentado en indicadores socioeconómicos objetivos, evitando el sesgo inherente a las encuestas tradicionales. Se integran datos heterogéneos de renta, mercado laboral y demografía de los más de 8.000 municipios españoles para caracterizar el entorno material del votante. La metodología emplea técnicas de *Gradient Boosting* tras una fase de ingeniería de variables que integra el Índice de Gini y relaciones de vecindad mediante Teoría de Grafos para capturar la influencia espacial y el sentimiento comarcal. El modelo, entrenado con datos de 2019 y validado con los resultados de 2023, reconstruye el arco parlamentario de 350 escaños aplicando la Ley D'Hondt a nivel provincial. Los resultados demuestran una elevada capacidad de inferencia, capturando patrones no lineales entre precariedad social y comportamiento electoral. Se concluye que las condiciones materiales de vida constituyen un rastro estadístico robusto para predecir la composición del Congreso, permitiendo una modelización política basada exclusivamente en datos objetivos.

Abstract

This work proposes a predictive model for general elections in Spain based on objective socioeconomic indicators, thereby avoiding the inherent bias of traditional polling. Heterogeneous data on income, labor market, and demographics from over 8,000 Spanish municipalities are integrated to characterize the material environment of the voter. The methodology employs *Gradient Boosting* techniques following a feature engineering phase that incorporates the Gini Index and neighborhood relationships through Graph Theory to capture spatial influence and regional sentiment. The model, trained on 2019 data and validated against 2023 results, reconstructs the 350-seat parliamentary arc by applying the D'Hondt rule at the provincial level. The results demonstrate a high inference capacity, capturing non-linear patterns between social precariousness and electoral behavior. It is concluded that material living conditions constitute a robust statistical trace for predicting the composition of the Congress, enabling political

modeling based exclusively on objective data.

**REVISAR TRAS COMPLETAR EL TRABAJO YA QUE
PUEDO TENER OTROS RESULTADOS**

Índice general

Resumen	I
1. Introducción y Objetivos	1
1.1. Introducción	1
1.2. Objetivos	2
1.2.1. Objetivo General	2
1.2.2. Objetivos Específicos	2
2. Marco Teórico y Estado del Arte	3
2.1. Teorías del Comportamiento Electoral	3
2.1.1. El Modelo Sociológico y la Identidad de Grupo	3
2.1.2. El Voto Económico: Teoría de la Recompensa y el Castigo	3
2.2. Evolución de la Predicción Electoral	3
2.2.1. Limitaciones de la Metodología Basada en Encuestas	3
2.2.2. Modelos Econométricos y de “Fundamentales”	3
2.3. Data Science Aplicado a la Ciencia Política	3
2.3.1. Algoritmos de Gradient Boosting en Series Temporales Sociales	4
2.3.2. Análisis Espacial y Teoría de Grafos en Sociología	4
2.4. El Sistema Electoral Español	4
3. Diseño del Proyecto	5

3.1. Origen y Adquisición de la Información	5
3.2. Arquitectura del Proyecto y Ciclo de Vida del Dato	6
3.2.1. Estructura de Almacenamiento y Repositorio	6
3.2.2. Procedimientos Técnicos y Pipeline	6
4. Análisis de los Resultados	8
4.1. Relación con las Materias del Máster	8
4.2. Resultados Obtenidos	8
5. Puesta en Marcha	9
6. Consideraciones Éticas y Sociales	10
7. Conclusiones, Estudio Económico y Futuro	11
7.1. Conclusiones	11
7.2. Estudio Económico	11
7.3. Líneas de Futuro	11
Bibliografía	12
A. Anexos	13

1. Introducción y Objetivos

1.1. Introducción

La predicción de los resultados electorales ha sido históricamente uno de los desafíos más complejos dentro de las ciencias sociales y la estadística aplicada. En el contexto español, el sistema de representación proporcional mediante la Ley D'Hondt y la división en 52 circunscripciones provinciales añade una capa de complejidad técnica que requiere una precisión extrema en la estimación del voto a nivel local. Tradicionalmente, este análisis se ha basado en encuestas de intención de voto y sondeos a pie de urna (*exit polls*). Sin embargo, estas metodologías enfrentan una crisis de fiabilidad creciente debido a fenómenos como el sesgo de respuesta, el aumento de los votantes indecisos y el denominado "voto oculto".

Este trabajo parte de la premisa de que el comportamiento electoral no es un fenómeno aislado de carácter puramente emocional, sino que responde de manera endógena a las condiciones materiales y socioeconómicas de los ciudadanos. La hipótesis central sostiene que los indicadores macroeconómicos y demográficos —tales como la renta per cápita, los niveles de desempleo, la desigualdad medida a través del Índice de Gini y la densidad de población— constituyen un rastro estadístico objetivo y medible. Al contrario que las encuestas, estos datos no dependen de la voluntad de comunicación del sujeto, sino de hechos económicos registrados oficialmente.

Mediante el uso de técnicas avanzadas de *Data Engineering* y algoritmos de *Machine Learning*, este proyecto propone un cambio de paradigma: la transición de una predicción basada en la opinión a una inferencia basada en la realidad socioeconómica. Se busca identificar patrones no lineales que vinculen la precariedad o la bonanza económica con tendencias ideológicas específicas, permitiendo modelizar la composición del Congreso de los Diputados sin recurrir a la consulta directa.

1.2. Objetivos

1.2.1. Objetivo General

Desarrollar y validar un sistema de inferencia predictiva que, mediante el análisis de indicadores socioeconómicos municipales y el uso de algoritmos de aprendizaje supervisado, sea capaz de estimar el reparto de los 350 escaños del Congreso de los Diputados en las elecciones generales españolas.

1.2.2. Objetivos Específicos

1. **Ingesta y Fusión de Datos Heterogéneos:** Diseñar un pipeline de datos para la extracción y limpieza de fuentes oficiales (INE, SEPE, IGN) y su integración en un dataset único a nivel municipal que abarque el periodo 2016-2023.
2. **Análisis Exploratorio y Correlacional:** Identificar las variables socioeconómicas con mayor poder predictivo y analizar su impacto en el sesgo de voto mediante técnicas de análisis multivariante.
3. **Modelado de Inferencia Predictiva:** Implementar y optimizar modelos de *Gradient Boosting* que capturen las relaciones complejas entre el entorno económico y la intención de voto, integrando componentes de influencia espacial.
4. **Desarrollo del Motor de Simulación Electoral:** Programar un módulo lógico que traduzca las predicciones de voto municipal en escaños reales, aplicando con rigor la normativa electoral vigente (barreras del 3 % y Ley D'Hondt).
5. **Validación y Backtesting:** Evaluar la precisión del modelo utilizando los resultados de las elecciones de 2023 como conjunto de prueba frente al entrenamiento basado en datos históricos anteriores.

2. Marco Teórico y Estado del Arte

2.1. Teorías del Comportamiento Electoral

En esta sección se analiza la evolución de las teorías del comportamiento político, desde el enfoque sociológico de la Escuela de Columbia hasta los modelos de elección racional. Esta base teórica es fundamental para justificar el uso de indicadores macroeconómicos como predictores de la intención de voto.

2.1.1. El Modelo Sociológico y la Identidad de Grupo

2.1.2. El Voto Económico: Teoría de la Recompensa y el Castigo

2.2. Evolución de la Predicción Electoral

Se examina la transición entre los métodos cualitativos y los modelos cuantitativos basados en datos estructurales.

2.2.1. Limitaciones de la Metodología Basada en Encuestas

2.2.2. Modelos Econométricos y de “Fundamentales”

2.3. Data Science Aplicado a la Ciencia Política

Estado actual de la integración de algoritmos de aprendizaje supervisado en el análisis de grandes volúmenes de datos sociales.

2.3.1. Algoritmos de Gradient Boosting en Series Temporales Sociales

2.3.2. Análisis Espacial y Teoría de Grafos en Sociología

2.4. El Sistema Electoral Español

Análisis técnico de la Ley D'Hondt y el impacto de la fragmentación del sistema de partidos tras el fin del bipartidismo en 2015.

3. Diseño del Proyecto

En este capítulo se describe la estrategia técnica adoptada para la resolución del problema planteado. El diseño se fundamenta en la construcción de un ecosistema de datos robusto y una arquitectura de procesamiento modular que permite transformar información administrativa bruta en conocimiento predictivo.

3.1. Origen y Adquisición de la Información

La construcción del dataset maestro ha requerido una fase intensiva de adquisición de datos procedentes de diversos organismos de la Administración Pública. La estrategia de obtención se ha centrado en capturar tres dimensiones críticas del electorado: su comportamiento histórico, su situación económica y su entorno demográfico-espacial.

Los resultados electorales y los datos de escrutinio municipal se han obtenido a través del portal de descargas del Ministerio del Interior [1], recuperando los registros detallados de los procesos de 2016, 2019 y 2023. Para la caracterización socioeconómica, el núcleo de la información proviene del Instituto Nacional de Estadística (INE), específicamente del Atlas de Distribución de Renta de los Hogares [2]. Esta fuente aporta indicadores de renta neta, fuentes de ingresos y métricas de desigualdad (Índice de Gini) que permiten modelizar el contexto material del votante. Debido a las particularidades del sistema foral, esta información se ha complementado con los microdatos de renta proporcionados por Nastat [3] para la Comunidad Foral de Navarra.

Adicionalmente, se ha integrado la visión coyuntural del mercado laboral mediante las estadísticas mensuales de paro y contratos del SEPE [4], así como la estructura demográfica oficial a través del Padrón Municipal del INE [5]. Finalmente, para dotar al modelo de una dimensión espacial, se han incorporado las delimitaciones territoriales del Instituto Geográfico Nacional [6] y, para la vertiente ideológica, las escalas de autopoicionamiento del Centro de Investigaciones Sociológicas [7]. Esta amalgama de fuentes heterogéneas constituye la base empírica sobre la que se asienta el resto de la arquitectura técnica.

3.2. Arquitectura del Proyecto y Ciclo de Vida del Dato

La arquitectura del sistema se ha diseñado bajo un enfoque de ingeniería de datos modular, asegurando que cada etapa del proceso sea reproducible y escalable. El flujo de trabajo se organiza siguiendo una estructura de directorios que refleja el ciclo de vida de la información: de lo "sucio"(*raw*) a lo "procesado".

3.2.1. Estructura de Almacenamiento y Repositorio

El proyecto se organiza en cuatro capas de datos y tres módulos lógicos de ejecución, lo que permite una clara separación de responsabilidades:

- **Capa de Datos Brutos (*data_raw/*):** Almacena la información original sin modificar, manteniendo la fidelidad a la fuente. Se organiza por categorías (renta, votos, mercado laboral, etc.).
- **Capa de Procesamiento Lógico (*limpieza/*):** Contiene los scripts ETL (*Extract, Transform, Load*) encargados de normalizar formatos, gestionar valores nulos y estandarizar las claves de unión (códigos INE municipales).
- **Capa de Datos Limpios (*data_processed/*):** Almacena los DataFrames resultantes tras la limpieza. Es la fuente de verdad para el análisis y el modelado.
- **Capa de Análisis y Modelado (*EDA/* y *calculos_electorales/*):** Donde se ejecutan los análisis estadísticos y el motor de la Ley D'Hondt.

3.2.2. Procedimientos Técnicos y Pipeline

El procedimiento operativo comienza con la ejecución de la función orquestadora `ETL_limpieza` dentro de `main.ipynb`, la cual invoca secuencialmente los módulos de la carpeta `limpieza/`. Una vez consolidado el dataset maestro en memoria, el sistema procede al Análisis Exploratorio de Datos (EDA) para validar correlaciones. Posteriormente, el motor de inferencia alimenta el módulo de simulación electoral, el cual traduce los votos predichos en escaños reales aplicando la normativa electoral vigente. Toda esta arquitectura se gestiona mediante el archivo

`config_path.json`, que centraliza las rutas y parámetros de configuración para garantizar la portabilidad del proyecto.

4. Análisis de los Resultados

4.1. Relación con las Materias del Máster

[Aquí debes vincular el trabajo con las asignaturas cursadas, como Estadística, Programación, Análisis de Datos, etc.]

4.2. Resultados Obtenidos

[Presentación de las visualizaciones del EDA y resultados de las simulaciones.]

5. Puesta en Marcha

[Guía de uso del proyecto, configuración del archivo `config_path.json` y ejecución del notebook `main.ipynb`.]

6. Consideraciones Éticas y Sociales

[Reflexión sobre el impacto del análisis de datos electorales, la privacidad y la transparencia algorítmica.]

7. Conclusiones, Estudio Económico y Futuro

7.1. Conclusiones

7.2. Estudio Económico

7.3. Líneas de Futuro

Bibliografía

- [1] Ministerio del Interior (2024). *Área de descargas de procesos electorales*. Gobierno de España. Recuperado de <https://infoelectoral.interior.gob.es/es/elecciones-celebradas/area-de-descargas/>
- [2] Instituto Nacional de Estadística (2024). *Atlas de distribución de renta de los hogares. Serie 2015-2023*. Recuperado de <https://www.ine.es/dynt3/inebase/index.htm?padre=12385&capsel=12384>
- [3] Instituto de Estadística de Navarra (2024). *Estadística de renta de las personas físicas y familia*. Recuperado de https://nastat.navarra.es/es/tablas_powerbi/-/tag/estadistica-renta
- [4] Servicio Público de Empleo Estatal (2024). *Datos estadísticos de paro y contratos por municipios*. Recuperado de <https://www.sepe.es/HomeSepe/que-es-el-sepe/estadisticas/datos-estadisticos/municipios.html>
- [5] Instituto Nacional de Estadística (2024). *Padrón municipal de habitantes*. Recuperado de https://www.ine.es/dyngs/INEbase/categoria.htm?c=Estadistica_P&cid=1254734710990
- [6] Instituto Geográfico Nacional (2024). *Delimitaciones Territoriales y Cartografía Municipal (NGMEP)*. Centro de Descargas del CNIG. Recuperado de <https://centrodedescargas.cnig.es/CentroDescargas/detalleArchivo?sec=90000004#>
- [7] Centro de Investigaciones Sociológicas (2022). *Barómetro de diciembre de 2022 (Estudio 3388)*. Recuperado de <https://www.cis.es/>

A. Anexos

[Tablas adicionales, fragmentos de código o manuales extendidos.]